Feature Engeneering

如果我们试图根据标普500指数过去的收益率来预测未来，那么整个预测过程都建立在一个假设之上：这个系统具有一定的稳定性。
换句话说，我们 **假设** 历史数据对未来具有参考价值（informative about the future）。
同样，如果我们掌握了某个人口群体的横截面数据，那么我们也可能利用样本来推断其他群体的情况。
但这种推断是否成立，同样取决于我们所作的假设。
有了这些假设，我们才能进一步讨论什么是通常的取值，以及什么情况属于极端事件。

教授先指向标普500日收益率的直方图，提到：

> Histograms can be a bit lumpy, but there are these ways of smoothing them.

意思是直方图可能有些凹凸不平，但我们可以用其他方法把数据分布表示得更加平滑。

接着，他指出图中的两条曲线：红色实线属于对数据分布的平滑估计，绿色虚线是根据某种预先设定的统计分布得到的理论曲线。结合 PPT，这里对应的是核密度估计和正态分布。

教授随后问了一个问题：

> Should I use the red? Should I use the green dotted? Should I just use the raw data?

“我应该使用红色曲线、绿色虚线，还是直接使用原始数据？”
他并没有马上给出唯一答案，而是说， **需要进一步挖掘数据，想清楚建模究竟要解决什么问题。**

这涉及三个不同的层次：
① 原始数据告诉我们实际发生过什么；② 核密度估计帮助我们较平滑地描述历史数据的概率分布；③ 正态分布提供了一个参数化的概率模型，但它是否适合实际金融数据，需要检验。

例如，正态分布可能不能充分刻画极端收益率，尤其是金融数据中的厚尾现象。
这里教授想让你理解的是： **统计模型的选择不能只依据图形是否平滑，还要考虑数据本身的特征以及模型的使用目的。**

接着，教授指向标普500的价格序列和收益率序列，提出：

> With time series data, getting rid of the trend.

在分析时间序列时， **需要考虑如何处理趋势** 。

之后，教授想说的是：标普500的价格存在明显的长期上升趋势，因此我们通常会转向分析收益率。
但换成收益率后，教授发现了一个新问题。

他指出2020年前后出现了较大的价格上下波动，并将这种波动幅度称为 volatility（波动率）。
他还比较了图中其他波动较小与较大的时期。
这说明，即便收益率序列没有价格序列那样明显的长期上升趋势，收益率的波动程度仍然可能随时间改变。

这里的 表示在已有历史信息条件下，当前收益率的条件方差。它可能在金融危机期间上升，在市场平静时期下降。

教授接着提出：

> So one thing we could do is try and pick the data apart.

也就是：我们可以尝试把数据分开研究。

紧接着他说：

> In periods of low volatility,what can we say? In periods of higher volatility,what can we say?

意思是：“在低波动时期，我们能得出什么结论？在高波动时期，我们又能得出什么结论？”
这两句话其实是整段视频的转折点。

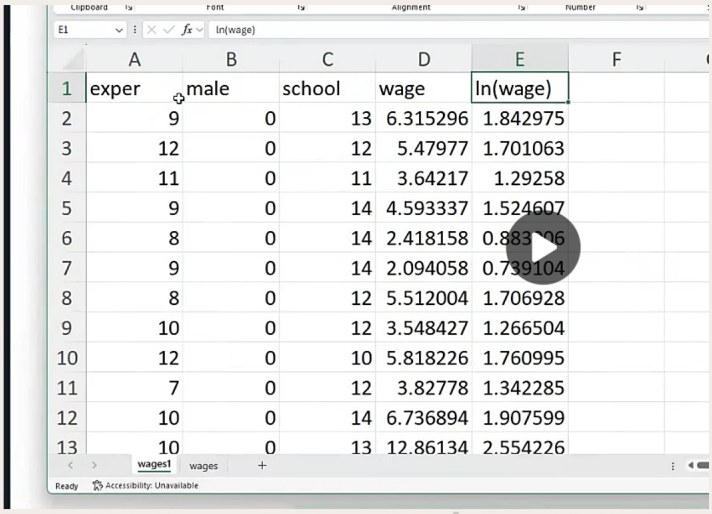
假设标普500存在两种市场状态：

比较内容	低波动时期	高波动时期
日收益率变化	相对集中	分散程度较大
收益率方差	较小	较大
极端收益率	相对少见	相对频繁
风险评估	相对较低	相对较高

如果我们把两种状态的数据全部混在一起，只绘制一张总体直方图，就可能掩盖不同市场状态之间的差异。

这也能进一步解释你之前问到的尖峰厚尾现象：**假如低波动期与高波动期的收益率分别近似服从不同方差的正态分布，混合后形成的总体分布就可能比单一正态分布具有更厚的尾部。**

接下来我们看一个这样的一个有3200左右样本的数据集

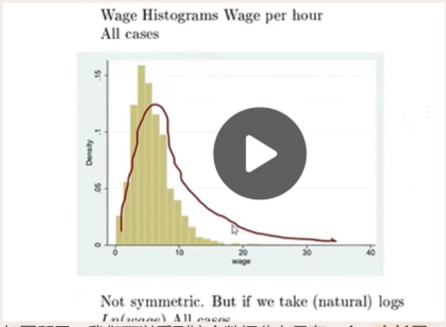


	A	B	C	D	E	F
1	exper	male	school	wage	ln(wage)	
2	9	0	13	6.315296	1.842975	
3	12	0	12	5.47977	1.701063	
4	11	0	11	3.64217	1.29258	
5	9	0	14	4.593337	1.524607	
6	8	0	14	2.418158	0.883106	
7	9	0	14	2.094058	0.739104	
8	8	0	12	5.512004	1.706928	
9	10	0	12	3.548427	1.266504	
10	12	0	10	5.818226	1.760995	
11	7	0	12	3.82778	1.342285	
12	10	0	14	6.736894	1.907599	
13	10	0	13	12.86134	2.554226	

第一列是工作经验，第二列是是否为男性的这个 虚拟变量，第三列是学龄，第四列是工资，第五列是把工资数据对数化

注意，对数化除了可以使得数据更平稳，还会 **让大数值的数据之间差异缩小**

然后我们可以用一个直方图画一下数据的分布

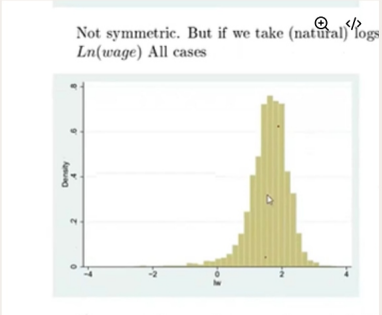


Not symmetric. But if we take (natural) logs

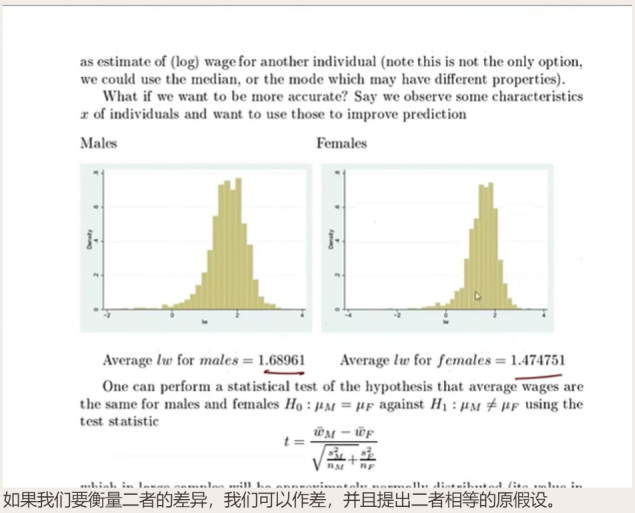
如图所示，我们可以看到这个数据分布具有一个 **右长尾**

当然，你也可以用上一讲 Probability and Statistics Background Material 的矩估计法，也就是计算平均值这些

然后我们对这个工资数据对数化，可以得到一个更类似于正态分布的数据分布图



如果里面的数据包含了性别信息，那么我可以把男女拆出来，就像这样



as estimate of (log) wage for another individual (note this is not the only option, we could use the median, or the mode which may have different properties).

What if we want to be more accurate? Say we observe some characteristics x of individuals and want to use those to improve prediction

Males Females

Average lw for $males = 1.68961$ Average lw for $females = 1.474751$

One can perform a statistical test of the hypothesis that average wages are the same for males and females $H_0 : \mu_M = \mu_F$ against $H_1 : \mu_M \neq \mu_F$ using the test statistic

$$t = \frac{\bar{w}_M - \bar{w}_F}{\sqrt{\frac{s_M^2}{n_M} + \frac{s_F^2}{n_F}}}$$

which in large samples will be approximately normally distributed (its value in

如果我们要衡量二者的差异，我们可以作差，并且提出二者相等的原假设。

我们就需要用样本均值差对应的统计量

为什么我们这里用t统计量而不是z统计量

其原因在于：决定使用 t 统计量还是 Z 统计量的主要因素，并非我们是否在比较两个样本均值，而是总体方差是否已知。

Z 统计量适用于什么情况

假设我们要检验男性和女性的平均工资是否相等：

$$H_0 : \mu_M = \mu_F$$

$$H_1 : \mu_M \neq \mu_F$$

如果我们已经知道男性和女性两个总体的真实方差 \sigma_M^2 和 \sigma_F^2，那么可以构造：

$$\boxed{Z = \frac{\bar{X}_M - \bar{X}_F}{\sqrt{\frac{\sigma_M^2}{n_M} + \frac{\sigma_F^2}{n_F}}}}$$

其中，分子是两个样本均值之差，分母是这个差值的标准误。

在原假设成立、两个样本独立，且总体正态或样本量足够大等条件下，Z 统计量服从或近似服从标准正态分布：

$$Z \sim N(0,1)$$

为什么我们经常需要用到t统计量

问题在于：**我们通常不知道总体的真实方差**。

比如，你随机调查了100名男性和100名女性，能够计算出各自的样本均值和样本方差，却无法直接知道所有男性、所有女性工资的总体方差。

因此，只能用样本方差 s_M^2 和 s_F^2 来估计总体方差：

$$\boxed{t = \frac{\bar{X}_M - \bar{X}_F}{\sqrt{\frac{s_M^2}{n_M} + \frac{s_F^2}{n_F}}}}$$

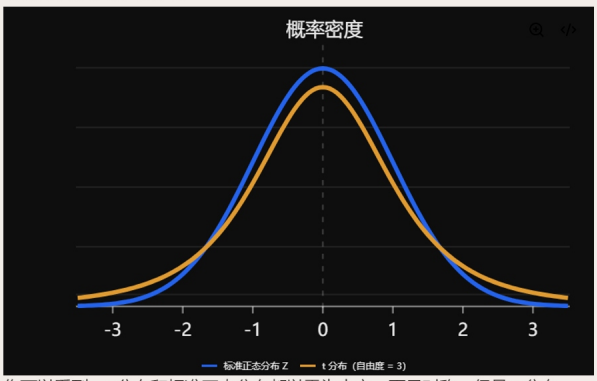
这就是你图片中教授写出的统计量。

但是，这里出现了一个问题：样本方差本身也具有随机性。换一批被调查者，我们算出的样本方差可能不同。

因此，在使用样本方差估计标准误时，统计量引入了额外的不确定性。

在满足相应条件时，它服从或近似服从 t 分布。

t分布和Z分布的区别在于：



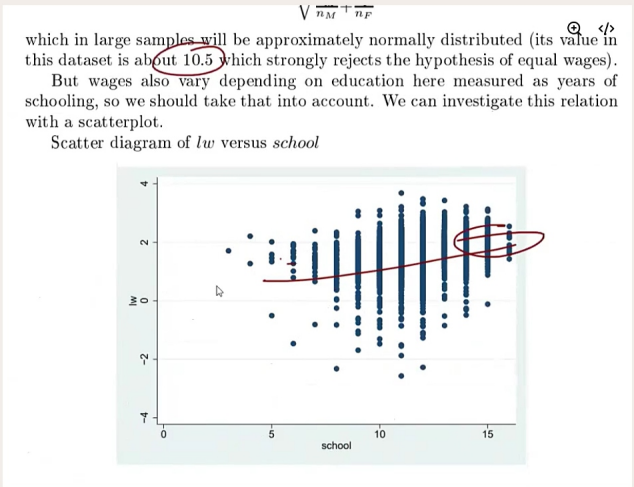
你可以看到，t 分布和标准正态分布都以零为中心，而且对称。但是 t 分布的尾部更厚，这是因为我们需要考虑估计总体方差所带来的额外不确定性。

随着样本量增加，自由度通常也会增大，t 分布会逐渐接近标准正态分布：

$$t_\nu \xrightarrow[\nu\to\infty]{d} N(0,1)$$

因此，在样本量非常大的时候，t 检验和 Z 检验往往会得到极为接近的结果。

除此之外，我们还可以看到

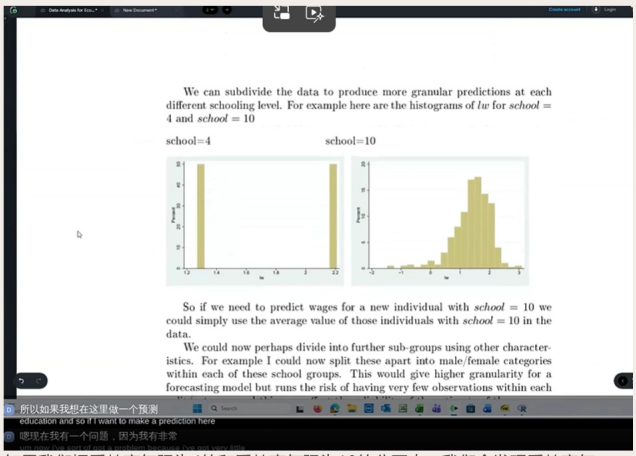

$$\sqrt{\frac{}{n_M}+\frac{}{n_F}}$$

which in large samples will be approximately normally distributed (its value in this dataset is about 10.5 which strongly rejects the hypothesis of equal wages).

But wages also vary depending on education here measured as years of schooling, so we should take that into account. We can investigate this relation with a scatterplot.

Scatter diagram of *lw* versus *school*

我们可以发现，受教育程度年限越长和对数工资的呈现正相关


We can subdivide the data to produce more granular predictions at each different schooling level. For example here are the histograms of *lw* for *school* = 4 and *school* = 10

school=4 school=10

So if we need to predict wages for a new individual with *school* = 10 we could simply use the average value of those individuals with *school* = 10 in the data.

We could now perhaps divide into further sub-groups using other characteristics. For example I could now split these apart into male/female categories within each of these school groups. This would give higher granularity for a forecasting model but runs the risk of having very few observations within each

所以如果我想在这里做一个预测
education and so if I want to make a prediction here
嗯现在我有一个问题，因为我有非常

如果我们把受教育年限为4的和受教育年限为10的分开来，我们会发现受教育年限为4的样本就两个，很难看出其规律

该部分小结：

教授先比较了男性与女性的平均对数工资：

$$\overline{lw_M} = 1.68961, \qquad \overline{lw_F} = 1.474751$$

通过两独立样本均值差异检验，得到统计量约为 10.5，因此强烈拒绝男女平均对数工资相等的原假设。

但这里存在一个问题：工资还受到教育年限的影响。

假设男性样本的平均受教育年限比女性更长，那么观察到的工资差距，可能部分来自教育年限的差异。

所以教授开始考察教育年限 school 与对数工资 lw 的关系。

你第一张图中的散点图说明，受教育年限越长，平均而言，对数工资往往越高。不过，这里只能说明存在正相关关系，还不能直接认定教育导致工资上涨。

你第二张截图中的两个直方图，正好说明了分组预测遇到的困难。

对于受教育年限为4年的人，只有两个观测值。即使能够计算出平均值，我们也很难确定这个平均值能否代表这一教育群体。

而受教育年限为10年的样本较多，我们就可以更可靠地估计这一组的条件均值，甚至观察组内工资的分布特征。

既然按教育年限分组可以改善预测，那么是否还可以进一步按照性别、年龄、职业进行划分？

理论上可以。例如：

$$E(lw \mid school = 10,\ female = 1)$$

表示受教育年限为10年的女性群体的平均对数工资。
这种分组更加具体，能够考虑更多个人特征。但随着条件不断增加，每个组包含的样本通常也会越来越少。

1. 为什么教授要把教育年限为4年和10年的人分开?
   这其实是在引入条件期望的思想。
   假设我们现在要预测一个人的对数工资。
   如果不考虑任何个人特征，最简单的方法就是使用全体样本的均值：

$$\widehat{lw} = \overline{lw}$$

   但如果我们知道这个人受过10年教育，显然可以利用这条额外信息。
   于是，我们把受教育年限恰好为10年的样本挑出来，计算他们的平均对数工资：

$$\widehat{E}(lw \mid school = 10) = \overline{lw}_{school=10}$$

   这就是利用条件均值进行预测。
   分组越细，组内个体越相似，但每组可供估计的样本也越少。
   前者有利于获得更有针对性的预测，后者却可能使估计的方差增加。这就涉及 偏差—方差权衡 。

下面我们转到更多的预测算法

KNN近邻算法

假设我们收集到下面这组数据。 **这些都是为讲解而编的数字，工资单位是千元/月。**
现在来了一个新人，我们只知道他受教育 **15 年**，想预测他的工资。

教育年限 x_i	月工资 y_i，千元	与 15 年相差多少
8	3	7
10	4	5
12	5	3
14	6	1
17	10	2
19	12	4
21	16	6

为了方便计算， **先取 k=3，意思是“参考最近的 3 个人”。**
第一步 算距离，找出最近的 3 个人
我们这里只使用教育年限这一个特征，所以两个人之间的距离，就用教育年限之差的绝对值：(用的是欧氏距离)

$$d_i = |x_i - 15|.$$

比如，教育 14 年的人，距离是：|14-15|=1.
教育 17 年的人，距离是：|17-15|=2.
教育 12 年的人，距离是：|12-15|=3.
其余人的距离都更大。因此，最近的 3 个邻居是教育年限为 **14、17、12 年** 的这三个人。
注意：**选邻居时，比较的是已知特征 X，在这里就是教育年限。** 新人的工资还不知道，无法按照工资是否接近来挑人。
第二步 把这 3 个人的工资取平均
他们的工资分别是：

$$6,\quad 10,\quad 5.$$

所以预测值是：

$$\hat{y} = \frac{6 + 10 + 5}{3} = 7.$$

也就是预测新人的月工资为 **7000 元**。
这已经完成了一次 kNN 回归预测。这里的两个数字要分清： **15 是新人的教育年限；3 是我们选取的邻居人数。**
接下来，我们推导" **为啥要用均值代表这三个实际值** "。
先设想一个理想情况：我们知道所有受教育 15 年的人的工资。
即使教育年限相同，他们的工资也可能不同。
因此，仅凭“教育年限为 15 年”，通常无法确定某个人的工资，但我们可以考虑这一人群的平均工资：

$$m(15) = E(Y \mid X = 15).$$

其中，X 表示教育年限，Y 表示工资；m(15)就是教育年限为 15 年的人群的平均工资。

问题是：**为什么这个平均数适合用来预测一个人的工资?**

答案可以从“让平均平方误差最小”推出来。

1. 假设你准备报出一个预测值 a

这个人的真实工资是 Y，那么预测误差为：Y-a.

平方误差为：(Y-a)^2.

现在考虑所有教育年限为 15 年的人，对他们的平方误差取平均，得到：

$$R(a) = E\left[(Y-a)^2 \mid X = 15\right].$$

你可以把 R(a)理解成：如果对教育 15 年的人都报出同一个工资 a，长期平均下来，会产生多大的平方误差?

我们的目标是找到让 R(a)最小的 a。

2. 展开平方

先用最普通的代数公式：

$$(Y-a)^2 = Y^2 - 2aY + a^2.$$

因此：

$$R(a) = E(Y^2 \mid X = 15) - 2aE(Y \mid X = 15) + a^2.$$

这里的 a 是你准备报出的一个固定数字，所以可以从期望中提出来。

对 a 求导：

第一项：

$$\frac{d}{da}E[Y^2 \mid X = 15] = 0$$

因为这里的条件期望不包含 a，所以对于 a 而言，它是一个常数。

第二项：

$$\frac{d}{da}[-2aE(Y \mid X = 15)]$$

因为 E(Y\mid X=15)不随 a 改变，所以：

$$= -2E(Y \mid X = 15)$$

相当于你在求：

$$\frac{d}{da}(5a) = 5$$

第三项：

$$\frac{d}{da}(a^2) = 2a$$

最终：

$$\boxed{R'(a) = -2E(Y \mid X = 15) + 2a}$$

令导数 =0：

$$-2E(Y \mid X = 15) + 2a = 0.$$

于是：

$$\boxed{a = E(Y \mid X = 15)}.$$

又因为：

$$R''(a) = 2 > 0,$$

所以这个位置确实取得最小值。

因此，**在以平均平方误差衡量预测好坏时，教育年限为 15 年这一人群的平均工资，就是最佳预测值。** 这个结论也可以推广到多个已知特征。

这一步告诉我们“想估计的目标是什么”：

$$\boxed{m(x_0) = E(Y \mid X = x_0)}.$$

但现实中，我们不知道这个总体条件均值，手里只有有限的样本。

第四步、为什么可以用“接近 15”的样本?

如果样本里有很多教育年限恰好为 15 年的人，我们可以直接计算他们的平均工资，用它估计 m(15)。

但刚才的表格中，一个教育年限恰好为 15 年的人都没有。

这时，kNN 使用了一个假设：

在我们关心的范围内，教育年限相近的人群，其平均工资也比较接近。

写成数学语言，就是：

$$x_i \text{ 接近 } 15 \quad \Longrightarrow \quad m(x_i) \text{ 接近 } m(15).$$

例如，我们希望：

$$m(14),\ m(17),\ m(12)$$

能为 m(15)提供一些参考。
但是这里说的是不同人群的 **平均工资** 接近。
个体工资还会受到教育年限以外的因素影响，同样受教育 14 年，两个人的工资也可能差很多。
为了把这两部分分开，我们写：

$$Y_i = m(x_i) + \varepsilon_i.$$

它的意思是：

$$\text{某个人的工资} = \text{该教育年限人群的平均工资} + \text{这个人偏离平均水平的部分}.$$

按照条件均值的定义 条件期望和内层条件期望 ，这个偏离部分满足：

$$E(\varepsilon_i \mid X_i = x_i) = 0.$$

这是非参数回归中常用的表示方式。
现在把附近 k 个人的工资取平均：

$$\frac{1}{k}\sum Y_i = \underbrace{\frac{1}{k}\sum m(x_i)}_{\text{附近人群的平均水平}} + \underbrace{\frac{1}{k}\sum \varepsilon_i}_{\text{个体偏离的平均}}.$$

这样，kNN 的思路就清楚了。

第一部分中，如果邻居确实足够接近，而且平均工资关系变化得不太剧烈，那么这些 m(x_i)的平均，有希望接近目标 m(15)。

第二部分中，参考多个人可以减轻某一个人偶然偏高或偏低的影响。在误差独立等条件下，这种减少波动的效果还能精确算出来，后面我们会推导。

所以，**使用"接近 15"的样本，是借助局部相似关系作出的近似。**

这也解释了它为什么可能失效：
假如平均工资恰好在某个学历门槛处发生明显跳变，门槛两侧即使教育年限接近，平均工资也可能相差很大。

第五步 为什么找到邻居后，最后一定算出平均数?
前面从总体上说明了：平方误差下，我们想估计条件均值。
现在回到手里的样本，看看"取平均"怎样从计算中出来。
刚才找到的三个邻居，工资分别为：

$$6,\quad 10,\quad 5.$$

我们想用一个数 a，概括这三个人附近的工资水平。如果要求它与这三个工资的**平方误差之和最小** ，就要最小化：

$$S(a) = (6-a)^2 + (10-a)^2 + (5-a)^2.$$

对 a 求导：

$$S'(a) = 2(a-6) + 2(a-10) + 2(a-5).$$

合并同类项：S'(a)=6a-42.
令导数为零：6a-42=0,
得到：a=7.
它正好等于：

$$\frac{6+10+5}{3}.$$

因为 S''(a)=6>0，这个平均数确实使 **平方误差之和最小** 。
将 3 个邻居推广到 k 个，就得到普通 kNN 回归公式：

$$\boxed{\widehat{m}_k(x_0) = \frac{1}{k}\sum_{i\in N_k(x_0)} y_i}.$$

这里，x_0 是待预测对象的已知特征(例如这里的工资)，N_k(x_0)表示距离它最近的 k 个样本的编号集合；求和时，把这些样本的结果 y_i 加起来，再除以人数 k。这是 kNN 回归的标准形式。
你可以把它理解成：每到一个待预测位置，就在附近选一组样本，拟合一个局部的常数。
换一个待预测位置，邻居可能发生变化，算出来的平均值也可能变化，因此它同样能形成一个从 X 到预测值的函数。

实际使用时，k 怎样确定?
刚才选择 k=3，是为了方便手算。实际应用时，可以尝试几个候选值，让它们分别预测没有参与训练的验证样本，再比较误差。
假设验证集中有

$$n_{\text{val}}$$

个样本，那么某个 k 对应的验证均方误差为：

$$\mathrm{MSE}_{\mathrm{val}}(k) = \frac{1}{n_{\mathrm{val}}} \sum_{j=1}^{n_{\mathrm{val}}} \left[y_j - \widehat{m}_k(x_j) \right]^2.$$

对每一个验证样本，都从 **训练集** 中寻找邻居、作出预测，再与已经知道的真实结果比较。通常根据验证集或交叉验证的表现选择 k，最后用独立测试集评价预测能力。

为什么不能只看训练集上的误差？因为在训练特征没有重复、允许样本把自己选作邻居的情况下，k=1 可以直接找回样本自己的结果，训练误差为零。这无法说明它对新人的预测也准确。

所以，**k 的好坏需要看它对未参与训练的数据预测得怎样。**

回归模型

其次，我们也可以构造一个回归模型进行预测

首先我们需要知道两个变量之间有没有线性关系，例如运用散点图

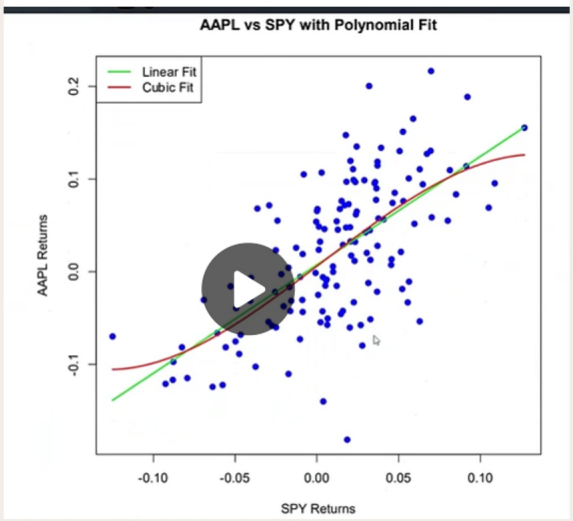
其次构建一元线性回归，当然也可以多项式回归
进而在确定模型之后，就可以开始计算相关系数，做假设、参数估计、假设检验

necessarily lie exactly on some well defined function).
For example we could specify a linear model

$$AAPL = a + b * SPY + e$$

Or a cubic relationship

$$AAPL = a + b_1 * SPY + b_2 * SPY^2 + b_3 * SPY^3 + e$$

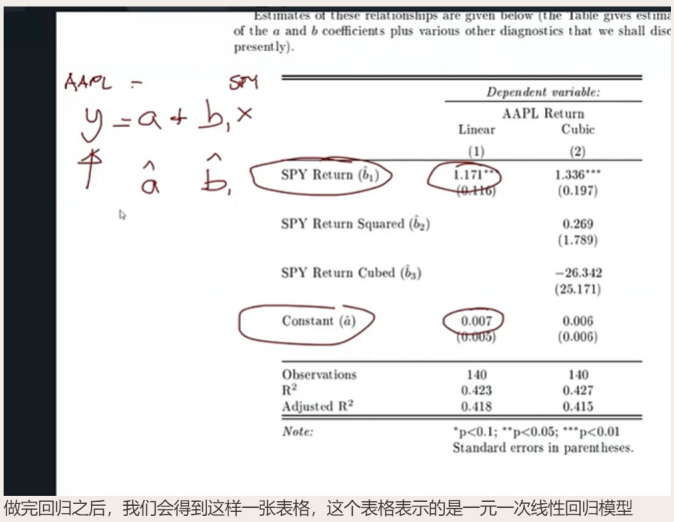


我们知道一元线性回归模型的一般形式是：

$$y = \alpha + \beta x + \epsilon$$

如果是三次幂线性回归模型就是：

$$y = \alpha + \beta x + \beta_2 x^2 + \beta_3 x^3 + \epsilon$$


Estimates of these relationships are given below (the Table gives estima
of the a and b coefficients plus various other diagnostics that we shall disc
presently).

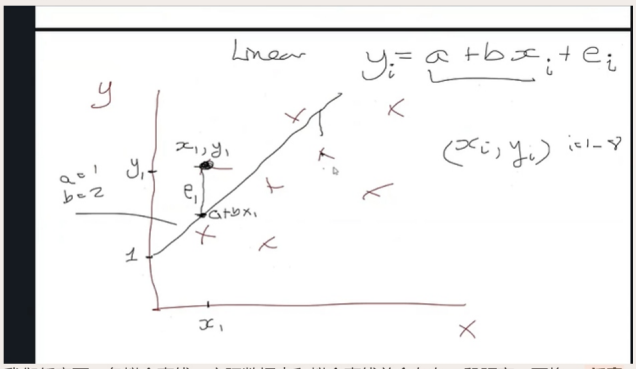
AAPL = SPY
$y = a + b_1 x$
$\hat{a}$ $\hat{b}_1$

	Dependent variable:	
	AAPL Return	
	Linear	Cubic
	(1)	(2)
SPY Return ($\hat{b}_1$)	1.171***	1.336***
	(0.116)	(0.197)
SPY Return Squared ($\hat{b}_2$)		0.269
		(1.789)
SPY Return Cubed ($\hat{b}_3$)		−26.342
		(25.171)
Constant ($\hat{a}$)	0.007	0.006
	(0.005)	(0.006)
Observations	140	140
R^2	0.423	0.427
Adjusted R^2	0.418	0.415
Note:	*p<0.1; **p<0.05; ***p<0.01	
	Standard errors in parentheses.	

做完回归之后，我们会得到这样一张表格，这个表格表示的是一元一次线性回归模型和一元三次线性回归模型的拟合效果
注意，“戴帽子”的系数是我们拟合出来的，而不戴帽子的α、β是真实的，是未知的系数
还有一个点，**是KNN近邻预测是非参数预测；但是线性回归模型的预测是参数预测，**

其模型是参数模型

原理：最小二乘法



我们任意画一条拟合直线，实际数据点和拟合直线总会存在一段距离，而将 **任意一个点yi - 在直线上的点y = ei,我们把它称之为残差**

我的目的是让所有的残差最小，那么我们可以这样来量化：

$$\min \sum_{i=1}^{n} e_i^2 = \min \sum_{i=1}^{n} (y_i - \alpha - \beta x_i)^2$$

我们使其残差最小，就是要找出一组合适的α和β使其最小

为了使其最小，求出系数，我们需要对该方程进行 微分,然后求偏导数：

根据微积分，如果一个可微函数在内部取得极小值，那么它对各个变量的一阶偏导数必须=0。

因此需要满足：

$$\begin{cases} \dfrac{\partial S}{\partial \alpha} = 0 \\ \dfrac{\partial S}{\partial \beta} = 0 \end{cases}$$

这就是 normal 方程的来源。

我们的目标函数：

$$S(\alpha, \beta) = \sum_{i=1}^{N} (y_i - \alpha - \beta x_i)^2$$

先看求和符号中的一个部分：

$$(y_i - \alpha - \beta x_i)^2$$

对（\alpha）求偏导。

这里需要使用复合函数求导法则：

$$\frac{d}{dt}[f(t)]^2 = 2f(t)f'(t)$$

因为：

$$\frac{\partial}{\partial \alpha}(y_i - \alpha - \beta x_i) = -1$$

所以：

$$\frac{\partial}{\partial \alpha}(y_i - \alpha - \beta x_i)^2 = 2(y_i - \alpha - \beta x_i)(-1)$$

即：

$$= -2(y_i - \alpha - \beta x_i)$$

再把所有观测值加起来：

$$\frac{\partial S}{\partial \alpha} = -2 \sum_{i=1}^{N} (y_i - \alpha - \beta x_i)$$

按照一阶极值条件，令偏导数=0：

$$-2 \sum_{i=1}^{N} (y_i - \hat{\alpha} - \hat{\beta} x_i) = 0$$

两边同时除以 -2：

$$\boxed{\sum_{i=1}^{N} (y_i - \hat{\alpha} - \hat{\beta} x_i) = 0}$$

这就是第一个 Normal Equation。

它还有一个很重要的统计学含义：

由于：

$$e_i = y_i - \hat{\alpha} - \hat{\beta} x_i$$

因此：

$$\boxed{\sum_{i=1}^{N} e_i = 0}$$

也就是说，带截距项的普通最小二乘回归中，样本残差之和=0。

对 \beta 求偏导

同样从目标函数出发

注意，\beta 前面乘了一个x_i，所以：

$$\frac{\partial}{\partial \beta}(y_i - \alpha - \beta x_i) = -x_i$$

根据复合函数求导法则：

$$\begin{aligned}&\frac{\partial}{\partial \beta}(y_i - \alpha - \beta x_i)^2\\&= 2(y_i - \alpha - \beta x_i)(-x_i)\\&= -2x_i(y_i - \alpha - \beta x_i)\end{aligned}$$

对全部观测值求和：

$$\frac{\partial S}{\partial \beta} = -2\sum_{i=1}^{N} x_i(y_i - \alpha - \beta x_i)$$

令偏导数等于零：

$$-2\sum_{i=1}^{N} x_i(y_i - \hat{\alpha} - \hat{\beta} x_i) = 0$$

两边同时除以 -2，得到：

$$\boxed{\sum_{i=1}^{N} x_i(y_i - \hat{\alpha} - \hat{\beta} x_i) = 0}$$

这就是你截图中的第二个 Normal Equation。

由于括号内就是残差 e_i，因此也可以写成：

$$\boxed{\sum_{i=1}^{N} x_i e_i = 0}$$

这意味着样本中解释变量 x_i 与残差 e_i 的乘积之和为零。由于样本残差的均值也为零，因此样本解释变量与残差的协方差为零。

求出拟合截距和拟合系数的表达式

现在我们得到了两个方程：

$$\begin{cases}\sum_{i=1}^{N}(y_i - \hat{\alpha} - \hat{\beta} x_i) = 0\\\sum_{i=1}^{N} x_i(y_i - \hat{\alpha} - \hat{\beta} x_i) = 0\end{cases}$$

实际上，这是一个关于

$$\hat{\alpha}, \hat{\beta}$$

的二元方程组。

第一步：从第一个正规方程求截距。

展开求和符号：

$$\sum_{i=1}^{N} y_i - N\hat{\alpha} - \hat{\beta}\sum_{i=1}^{N} x_i = 0$$

移项：

$$N\hat{\alpha} = \sum_{i=1}^{N} y_i - \hat{\beta}\sum_{i=1}^{N} x_i$$

两边除以 N：

$$\hat{\alpha} = \frac{\sum y_i}{N} - \hat{\beta}\frac{\sum x_i}{N}$$

我们知道：

$$\bar{y} = \frac{\sum y_i}{N}, \qquad \bar{x} = \frac{\sum x_i}{N}$$

因此：

$$\boxed{\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}}$$

第二步：将截距公式代入第二个正规方程。

原方程展开后：

$$\sum x_i y_i - \hat{\alpha}\sum x_i - \hat{\beta}\sum x_i^2 = 0$$

代入

$$\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$$

：

$$\sum x_i y_i - (\bar{y} - \hat{\beta}\bar{x})\sum x_i - \hat{\beta}\sum x_i^2 = 0$$

整理：

$$\hat{\beta}\left(\sum x_i^2 - \bar{x}\sum x_i\right) = \sum x_i y_i - \bar{y}\sum x_i$$

利用

$$\sum x_i = N\bar{x}$$

，得到：

$$\hat{\beta} = \frac{\sum x_i y_i - N\bar{x}\bar{y}}{\sum x_i^2 - N\bar{x}^2}$$

又因为：

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = \sum x_i y_i - N\bar{x}\bar{y}$$

以及：

$$\sum (x_i - \bar{x})^2 = \sum x_i^2 - N\bar{x}^2$$

最终得到：

$$\boxed{\hat{\beta} = \frac{\sum_{i=1}^{N}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{N}(x_i - \bar{x})^2}}$$

让我们回到原来的例子

老师写下：

$$\ln(wage_i) = \alpha + \beta\, male_i + e_i.$$

这里的解释变量和被解释变量分别是：

$$y_i = \ln(wage_i), \qquad x_i = male_i = \begin{cases} 0, & \text{女性}, \\ 1, & \text{男性}. \end{cases}$$

也就是说，你前面的最小二乘公式仍然适用，只是现在知道了每个符号对应的实际内容：**y_i 是第 i 个人的对数工资，x_i 是他所属组别的编码。**

我们先看**估计完成后的拟合式**：

$$\hat{y}_i = \hat{\alpha} + \hat{\beta}\, male_i.$$

把 0 和 1 分别代进去：

这个人属于哪一组	$male_i$	模型给出的拟合值
女性组	0	$\hat{\alpha}+\hat{\beta}\times 0=\hat{\alpha}$
男性组	1	$\hat{\alpha}+\hat{\beta}\times 1=\hat{\alpha}+\hat{\beta}$

所以，这个模型给女性组安排了一个预测水平 \hat\alpha，给男性组安排了另一个预测水平 \hat\alpha+\hat\beta。

两组预测水平之间的差，就是 \hat\beta：

$$(\hat{\alpha}+\hat{\beta})-\hat{\alpha}=\hat{\beta}.$$

这里已经可以看出，为什么老师会用这个模型研究男女工资差异。 **只要估计出 \hat\beta，两组预测水平相差多少就有了答案。**

但这里还需要补上一步： **为什么最小二乘法选出来的这两个预测水平，恰好是各组的样本均值?**

刚推导的两个正规方程，在这里正好派上用场

你已经得到了：

$$\sum_{i=1}^{n} e_i = 0, \qquad \sum_{i=1}^{n} x_i e_i = 0.$$

在这个例子里，x_i=male_i，所以第二个方程变成：

$$\sum_{i=1}^{n} male_i e_i = 0.$$